

## Sprawozdanie 2

### Lista 5, 6 i 7

#### Zad 1

***binom.test*** jest to funkcja przeprowadzająca test dokładności dla prostej hipotezy zerowej  $H_0$  o prawdopodobieństwie sukcesu w próbie Bernoulliego.

Użycie:

```
binom.test(x, n, p = 0.5, alternative = c("two.sided", "less", "greater"),
           conf.level = 0.95)
```

gdzie:

- x jest liczbą sukcesów,
- n to liczba prób,
- p to prawdopodobieństwo sukcesu,
- alternative oznacza hipotezę alternatywną  $H_1$ ,
- conf.level - poziom ufności.

***prop.test*** jest to funkcja sprawdzająca czy prawdopodobieństwa sukcesu w kilku próbkach są takie same, oraz czy są równe pewnym wartościom.

Użycie:

```
prop.test(x, n, p = NULL, alternative = c("two.sided", "less", "greater"),
          conf.level = 0.95, correct = TRUE)
```

gdzie:

- x jest wektorem z liczbą sukcesów w każdej grupie,
- n to wektor z liczbą prób w każdej grupie,
- p to wektor z prawdopodobieństwami sukcesu w każdej grupie,
- alternative oznacza hipotezę alternatywną  $H_1$ ,
- conf.level - poziom ufności,
- correct - definiujemy, czy funkcja powinna zastosować poprawkę na ciągłość.

W powyższych testach pojawia się argument *alternative*, oznacza on jaką postać hipotezy alternatywnej  $H_1$  chcemy rozważać:

- alternative="two.sided", wtedy:  $H_1 : \theta_1 \neq \theta_2$ ,
- alternative="greater", wtedy:  $H_1 : \theta_1 > \theta_2$ ,
- alternative="less", wtedy:  $H_1 : \theta_1 < \theta_2$ ,

## Zad 2

Założmy, że 200 losowo wybranych klientów (w różnym wieku) kilku (losowo wybranych) aptek zapytano, jaki lek przeciwbólowy zwykle stosują. Zebrane dane zawarte są w tablicy 1.

Lek	Wiek ankietowanych			Suma
	do lat 35	od 36 do 55	powyżej 55	
Lbuprom	35	0	0	35
Aap	22	22	0	44
Paracetamol	15	15	15	45
Ibuprofen	0	40	10	50
Panadol	18	3	5	26
Suma	90	80	30	200

Tabela 1. Dane do zad 2. i 3.

a)

Prawdopodobieństwo, że losowo wybrana osoba z badanej populacji w przypadku bólu zażywa Apap jest mniejsze bądź równe  $1/4$ :

```
binom.test(44, 200, p=1/4, alternative = "g")$p.value
## [1] 0.8562401

prop.test(44, 200, p=1/4, alternative = "g", correct = T)$p.value
## [1] 0.8154462

prop.test(44, 200, p=1/4, alternative = "g", correct = F)$p.value
## [1] 0.8364066
```

Każda z powyższych p-wartości jest większa niż 0,05, zatem w żadnym z powyższych testów nie możemy odrzucić hipotezy, że prawdopodobieństwo, że losowo wybrana osoba z badanej populacji w przypadku bólu zażywa Apap jest mniejsze bądź równe  $1/4$ .

b)

Prawdopodobieństwo, że losowo wybrana osoba z badanej populacji w przypadku bólu zażywa Apap jest równe  $1/2$ :

```
binom.test(44, 200, p = 0.5, alternative = "t")$p.value
## [1] 6.837911e-16

prop.test(44, 200, p = 0.5, alternative = "t", correct = T)$p.value
## [1] 4.197514e-15

prop.test(44, 200, p = 0.5, alternative = "t", correct = F)$p.value
## [1] 2.382836e-15
```

Widzimy zatem, że p-wartości w każdym teście są mniejsze niż 0,05, zatem odrzucamy hipotezę, że prawdopodobieństwo, że losowo wybrana osoba z badanej populacji w przypadku bólu zażywa Apap jest równe  $1/2$ .

c)

Prawdopodobieństwo, że losowo wybrana osoba z badanej populacji w przypadku bólu zażywa Ibuprofen jest większe bądź równe  $1/5$ :

```
binom.test(50, 200, p=1/5, alternative = "l")$p.value
## [1] 0.9655032
prop.test(50, 200, p=1/5, alternative = "l", correct = T)$p.value
## [1] 0.9534609
prop.test(50, 200, p=1/5, alternative = "l", correct = F)$p.value
## [1] 0.9614501
```

Każda z powyższych p-wartości jest większa niż 0,05, zatem w zadanym z powyższych testów nie możemy odrzucić hipotezy, że prawdopodobieństwo, że losowo wybrana osoba z badanej populacji w przypadku bólu zażywa Ibuprofen jest większe bądź równe  $1/5$ .

d)

Powtórzyć punkt (a), (b) i (c), ale dla osoby z badanej populacji do lat 35:

```
binom.test(22, 90, p=1/4, alternative = "g")$p.value
## [1] 0.5885826
prop.test(22, 90, p=1/4, alternative = "g", correct = T)$p.value
## [1] 0.5
prop.test(22, 90, p=1/4, alternative = "g", correct = F)$p.value
## [1] 0.5484381
```

Tak samo jak w podpunkcie **a)** nie odrzucamy badanej hipotezy.

```
binom.test(22, 90, p = 0.5, alternative = "t")$p.value
## [1] 1.249258e-06
prop.test(22, 90, p = 0.5, alternative = "t", correct = T)$p.value
## [1] 2.101436e-06
prop.test(22, 90, p = 0.5, alternative = "t", correct = F)$p.value
## [1] 1.241945e-06
```

Tak samo jak w podpunkcie **b)** odrzucamy badaną hipotezę.

```

binom.test(0, 90, p=1/5, alternative = "l")$p.value
## [1] 1.897138e-09
prop.test(0, 90, p=1/5, alternative = "l", correct = T)$p.value
## [1] 1.997379e-06
prop.test(0, 90, p=1/5, alternative = "l", correct = F)$p.value
## [1] 1.050718e-06

```

W tym przypadku widzimy że p-wartości w każdym z wykonanych testów jest bliska 0, więc odrzucamy badaną hipotezę.

### Zad 3

Na podstawie danych w tablicy 1, korzystając z testu Fishera, na poziomie istotności  $\alpha = 0.05$ , zweryfikować hipotezę, że prawdopodobieństwo, że osoba do lat 35 zażywa Panadol jest równe prawdopodobieństwu, że osoba od 36 lat do 55 lat zażywa Panadol.

Czy na podstawie uzyskanego wyniku można (na zadanym poziomie istotności) odrzucić hipotezę o niezależności wyboru leku Panadol w leczeniu bólu od wieku, przy uwzględnieniu tylko dwóch grup wiekowych - do lat 35 i od 36 do 55 lat?

***fisher.test*** jest to funkcja przeprowadzająca test dokładności dla hipotezy zerowej  $H_0$  o niezależności kolumn i wierszy w tabeli dwudzielczej.

Użycie:

```
fisher.test(x, alternative = "two.sided", conf.level = 0.95, simulate.p.value = FALSE)
```

gdzie:

- x jest dwuwymiarową macierzą,
- alternative oznacza hipotezę alternatywną  $H_1$ ,
- conf.level - poziom ufności,
- simulate.p.value ustawienie tego parametru na True sprawi, że metoda sama wysymuluje p-wartości za pomocą metody Monte Carlo,
- funkcja posiada również inne argumenty, takie jak np. *workspace, hybrid, percent* itp., jednakże nie używamy ich więc objaśnianie jest zbędne.

Lek	Wiek ankietowanych	
	do lat 35	od 36 do 55
Panadol	18	3
Inny	72	77

Tabela 2. Tabela do zadania 3.

```
fisher.test(data2)$p.value
```

```
## [1] 0.001788538
```

Jak widzimy p-wartość jest mniejsza od przyjętego poziomu istotności  $\alpha = 0.05$ , zatem odrzucamy hipotezę o niezależności rozkładów. Zatem badane rozkłady warunkowe nie są jednorodne.

#### Zad 4

Korzystając z funkcji `chisq.test` w pakiecie R, na poziomie istotności 0.05, zweryfikować hipotezę o niezależności stopnia zadowolenia z pracy i wynagrodzenia na podstawie danych w tabelicy 2. Zwrócić uwagę na stosowaną w tej funkcji poprawkę.

Wynagrodzenie	Zadowolenia				Suma
	b. niezadow.	niezadow.	zadow.	b. zadow.	
do 6000	20	24	80	82	206
6000-15000	22	38	104	125	289
15000-25000	13	28	81	113	235
powyżej 25000	7	18	54	92	171
Suma	62	108	5	26	901

Tabela 3. Dane do zadania 4.

```
chisq.test(data3[1:4,1:4],correct = F)$p.value
```

```
## [1] 0.2139542
```

Jak możemy zobaczyć p-wartość jest większa od przyjętego poziomu istotności  $\alpha = 0.05$ , zatem nie mamy podstaw do odrzucenia hipotezy o niezależności rozkładów warunkowych.

## Zad 5

Napisać deklarację funkcji, która dla danych w tablicy dwudzielczej oblicza wartość poziomu krytycznego (p-value) w asymptotycznym teście niezależności opartym na ilorazie wiarygodności. Korzystając z napisanej funkcji, obliczyć tę wartość dla danych z zadania 4.

Wyliczenie p-wartości dla testu opartego na ilorazie wiarygodności oparte jest na statystyce:

$$G^2 = -2 \log(\lambda), \quad \lambda = \prod_{i,j} \left( \frac{n_{i+} n_{+j}}{n n_{ij}} \right)^{n_{ij}},$$
$$\text{p-value} = 1 - F_{\chi^2(R-1)(C-1)}(G^2),$$

gdzie:

- $n_{i+}$  - suma licznosci w i-tym wierszu,
- $n_{+j}$  - suma licznosci w j-tej kolumnie,
- $n_{ij}$  - licznosc w i-tym wierszu i j-tej kolumnie,
- $n$  - liczba wszystkich ankietowanych,
- $R$  - liczba wierszu testowanej tabeli,
- $C$  - liczba kolumn testowanej tabeli.

Powyższa statystyka przy założeniu hipotezy o niezależności, dąży przy  $n \rightarrow \infty$  do rozkładu  $\chi^2$  z  $(R-1)(C-1)$  stopniami swobody.

```
p <- function(dane) {  
  y_xo <- rowSums(dane)  
  y_ox <- colSums(dane)  
  
  n <- sum(dane)  
  r <- nrow(dane)  
  c <- ncol(dane)  
  x <- 1  
  for (i in 1:r) {  
    for (j in 1:c) {  
      y_ij <- dane[i,j]  
      x <- ( ( y_xo[i]*y_ox[j] ) / (y_ij*n) )^y_ij * x  
    }  
  }  
  g_2 <- -2 * log(x)  
  return( 1-pchisq(g_2, (c-1)*(r-1)) )  
}  
p(data3[1:4,1:4])[[1]]  
## [1] 0.2112391
```

Jak możemy zobaczyć p-wartość jest większa od przyjętego poziomu istotności  $\alpha = 0.05$ , zatem nie mamy podstaw do odrzucenia hipotezy o niezależności rozkładów warunkowych. Porównując p-wartości w zadaniu czwartym i piątym których wartości wynosiły odpowiednio 0.2139542 i 0.2112391, widzimy że obie metody w tym przypadku dają wyniki bardzo do siebie zbliżone.

## Lista 8 i 9

W kolejnych zadaniach będziemy zajmować się zmiennością danych. Będziemy ją mierzyć za pomocą kilku współczynników, które zdefiniujemy poniżej:

— współczynnik V Cramera:

$$V = \sqrt{\frac{X^2}{n \min\{R-1, C-1\}}}, \quad (1)$$

— współczynnik T-Czuprowa:

$$T = \sqrt{\frac{X^2}{n\sqrt{(R-1)(C-1)}}}, \quad (2)$$

— współczynnik  $\varphi$ :

$$\varphi = \sqrt{\frac{X^2}{n}} \quad (3)$$

— współczynnik C Pearsona (coefficient of contingency):

$$C = \sqrt{\frac{X^2}{X^2 + n}} \quad (4)$$

— współczynnik  $\hat{\gamma}$ :

$$\hat{\gamma} = \frac{N_c - N_d}{N_c + N_d} \quad (5)$$

— współczynnik  $\hat{\tau}$  Goodmana

$$\hat{\tau} = \frac{\sum_{i=1}^R \sum_{j=1}^C \frac{n_{ij}^2}{nn_{i+}} - \sum_{j=1}^C \left(\frac{n_{+j}}{n}\right)^2}{1 - \sum_{j=1}^C \left(\frac{n_{+j}}{n}\right)^2} \quad (6)$$

Powyższa miara określa stopień redukcji zmienności zmiennej  $W_2$ , przy znajomości zmiennej  $W_1$ . Przyjmuje on wartości z zakresu  $[0, 1]$ . Gdy  $\tau = 0$ , to wtedy i tylko wtedy zmienne  $W_1$  i  $W_2$  są niezależne.  $\tau = 1$ , wtedy i tylko wtedy, gdy dla każdego  $i \in \{1, \dots, R\}$  istnieje  $j \in \{1, \dots, C\}$  takie, że  $p_{j|i} = 1$ .

Powyższe miary zdefiniowaliśmy w R:

```

tau <- function(data) {
  p <- data/sum(data)
  pi. <- rowSums(p)
  p.i <- colSums(p)
  R <- nrow(data)
  C <- ncol(data)
  d1 <- 0
  for (i in 1:R) {
    for (j in 1:C) {
      d1 <- p[i, j]^2/pi.[i] + d1
    }
  }
  d2 <- sum(p.i^2)
  return( ( d1 - d2 )/(1 - d2) )}

```

```

wspolczynniki <- function(dane,metoda){
  X <- chisq.test(dane)$statistic[[1]]
  R <- nrow(dane)
  C <- ncol(dane)
  n <- sum(dane)
  if (metoda=="v-cramer"){
    sqrt(X/(n*min(R-1,C-1)))
  }else if (metoda == 't-czuprow'){
    sqrt(X/(n*sqrt((R-1)*(C-1))))
  }else if (metoda=="phi"){
    (X/n)**0.5
  }else if (metoda=="c-pearson"){
    (X/(X+n))**0.5
  }else if (metoda=="tau"){
    tau(dane)
  }else if (metoda=="gamma"){
    a <- 0
    for (i in 1:nrow(dane)-1){
      for (j in 1:ncol(dane)-1){
        a <- a + sum(dane[i,j]) *
          sum(dane[min(i+1,nrow(dane)):nrow(dane),
            min(j+1,ncol(dane)):ncol(dane)])
      }
    }
    b <- 0
    for (i in 1:nrow(dane)-1){
      for (j in ncol(dane):2){
        b <- b + sum(dane[i,j]) *
          sum(dane[min(i+1,nrow(dane)):nrow(dane),
            max(j-1,1):1])
      }
    }
  }
}

```



```
}  
(a-b)/(a+b)}}
```

## Inercja

Inercję całkowitą można zinterpretować jako miarę rozporoszenia profili w przestrzeni wielowymiarowej. Im większa jest inercja całkowita układu, tym punkty w tej przestrzeni są bardziej rozproszone.

$$\lambda = \sum_{i=1}^K \gamma_i^2 \quad (7)$$

gdzie:  $\lambda_i$  to wartości osobliwe macierzy A, które jednocześnie znajdują się w diagonalnej macierzy  $\Gamma$ , możemy również wyznaczyć współczynnik inercji częściowej:

$$\lambda_c = \frac{\sum_{i=1}^2 \gamma_i^2}{\lambda} \quad (8)$$

## Zad. 1

Tabele z przykładu 1 wykład 7:

```
m1a=matrix(c(888, 369, 50, 457,
             263, 95, 10, 99,
             208, 29, 2, 44,
             78, 9, 0, 19,
             1, 0, 0, 4), nrow=5, byrow=TRUE)
m2a=matrix(c(505, 202, 19, 136,
             240, 77, 14, 88,
             181, 63, 8, 105,
             512, 159, 21, 294), nrow=4, byrow=TRUE)
m1b=matrix(c(888, 369, 50, 457,
             263, 95, 10, 99,
             208, 29, 2, 44,
             79, 9, 0, 23), nrow=4, byrow=TRUE)
m1c=matrix(c(888, 369, 50, 457,
             263, 95, 10, 99,
             287, 38, 2, 67), nrow=3, byrow=TRUE)
```

	$\tau$	V	T	$\varphi$	C
m1a	0.01712	0.10292	0.09578	0.17827	0.17550
m1b	0.01508	0.09627	0.09627	0.16675	0.16448
m1c	0.01490	0.11682	0.10556	0.16521	0.16300
m2a	0.01013	0.09116	0.09116	0.15789	0.15596

Tabela 4. Tablica wartości współczynników dla poszczególnych macieży dla adania 1.

Jak możemy zobaczyć otrzymana wartość współczynnika  $\tau$  jest bliska zeru, świadczy to o bardzo małej współzmienności badanych zmiennych losowych.

```

inercja <- function(data) {
  p <- data/sum(data)
  r <- rowSums(p)
  c <- colSums(p)
  R <- nrow(data)
  C <- ncol(data)
  P<- matrix(p,R,C)
  D_r <- diag(r)
  D_c <- diag(c)
  A <- sqrt( inv(D_r) ) %*% ( P - r %*% t(c) ) %*% sqrt( inv(D_c) )
  B <- diag(A %*% t(A))
  g <- diag(svd(A)$d)
  return(c( sum( B ), (g[1,1]^2+g[2,2]^2)/sum(g^2) ) )
}

```

	$\lambda$	inercja cz.
m1a	0.03178	0.99631
m1b	0.02780	0.99648
m1c	0.02730	1.00000
m2a	0.02493	0.99586

Tabela 5. tablica wartości współczynników inercji macierzy dla zadania 1.

Dla badanych tabel przeprowadzona analiza korespondencji wykazała, że dwa wymiary wystarczą, aby objaśnić ponad 99.5% zmienności, a w tabeli m1c nawet 100%. W każdym przypadku inercja całkowita jest bardzo mała, co świadczy o niewielkim rozproszeniu punktów w przestrzeni wielowymiarowej.

```


analiza <- function(data) {
  p <- data/sum(data)
  r <- rowSums(p)
  c <- colSums(p)
  R <- nrow(data)
  C <- ncol(data)
  P<- matrix(p,R,C)
  D_r <- diag(r)
  D_c <- diag(c)
  A <- sqrt( inv(D_r) ) %*% ( P - r %*% t(c) ) %*% sqrt( inv(D_c) )
  s <- svd(A)
  U <- s$u
  D <- diag(s$d)
  V <- s$v
  F <- sqrt( inv(D_r) ) %*% U %*% D
  G <- sqrt( inv(D_c) ) %*% V %*% D
  F_df <- data.frame(
    x = c(F[,1],G[,1]),

```

```

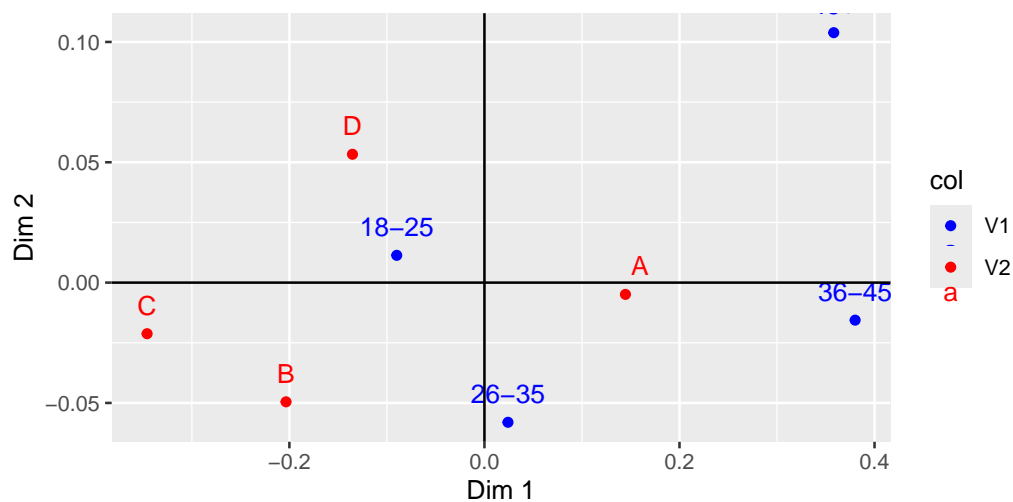
y = c(F[,2],G[,2]),
name = c(rownames(p),colnames(p)),
col = c(rep("V1",R),rep("V2",C))
)
return(F_df)
}

```



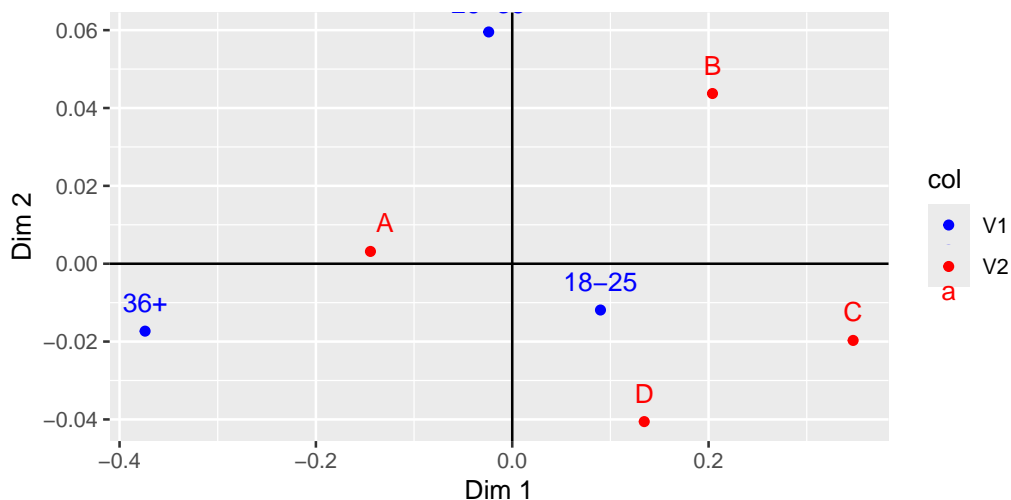
Rysunek 1. Analiza korespondencji dla tabeli m1a.

Na wykresie zauważamy, że nie istnieją silne powiązania między zmiennymi, wszystkie skupione są blisko początku układu współrzędnych (punktu (0,0)). Kategoria "60+" cechuje się zdecydowanie największą rozróżnialnością, na co wskazują duża odległość od wcześniej wspomnianego punktu.




Rysunek 2. Analiza korespondencji dla tabeli za m1b.

Połączenie kategorii "60+" z kategorią "46-59" nie zmienia znacząco wartości punktów na wykresie, jest to spowodowane tym, że w kategorii "60+" znajduje się tylko 8 osób.



Rysunek 3. Analiza korespondencji dla tabeli za m1c.

Połączenie kategorii "46+" z kategorią "36-45" wpłynęło na kształt wykresu, teraz osoby w wieku "18-25" wykazują największe powiązanie ze "segreguje śmieci, ponieważ każdy tak robi" i nie są skłonni do niesegregowania śmieci. Natomiast kategorie "36+" i "26-35" są najbardziej oddalone od początku układu współrzędnych co wskazuje, że są najbardziej rozróżnialne.



Rysunek 4. Analiza korespondencji dla tabeli za m2a.

Z wykresu możemy wywnioskować, że osoby z miast liczących ponad 50 tysięcy mieszkańców i od 20 do 50 tysięcy mieszkańców są najbardziej związani z odpowiedzią "nie segreguje śmieci". Spora korespondencja występuje

między mieszkańcami wsi a odpowiedzią "segreguje śmieci ponieważ tak nakazuje prawo", a mieszkańcy miast do 20 tysięcy mają najsilniejsze powiązanie z odpowiedzią "segreguje śmieci, ponieważ wszyscy tak robią"

## Zad 2

Założmy, że 200 klientów (w różnym wieku) kilku aptek zapytano, jaki lek przeciwbólowy zwykle stosują. Zebrane dane zawarte są w tablicy 2. Na podstawie tych danych, obliczyć odpowiednie miary współzmienności oraz przeprowadzić analizę korespondencji, tzn. obliczyć wartości odpowiednich macierzy, współrzędnych punktów oraz utworzyć odpowiednie wykresy.

Lek	Wiek ankietowanych		
	do lat 35	od 36 do 55	powyżej 55
Ibuprom	35	0	0
Aap	22	22	0
Paracetamol	15	15	15
Ibuprofen	0	40	10
Panadol	18	3	5

Tabela 6. Dane do listy 8 i 9, zadanie 2.

	$\tau$	V	T	$\varphi$	C
1	0.34772	0.53612	0.45082	0.75818	0.60416


Tabela 7. Tablica wartości współczynników dla zadania 2.

Tabela w tym zadaniu nie jest rozmiaru 2x2, więc powinniśmy rozpatrzeć tylko współczynnik  $\tau$ . Jak możemy zobaczyć otrzymana wartość tego współczynnika wskazuje na to, że zmienna *Lek* ma wpływ na redukcję zmienności zmiennej *Wiek*.

	$\lambda$	inercja cz.
Zad 2	0.57484	1.00000

Tabela 8. tablica wartości współczynników inercji macierzy dla zadania 2.

Z przeprowadzonej analizy korespondencji wynika, że inercja całkowita wynosi 0.57484, a w dwóch wymiarach objaśnione jest aż 100% zmienności.



Rysunek 5. Analiza korespondencji dla Tabeli 1.

Na wykresie widzimy, że silne powiązanie występuje między zmiennymi "Ibuprom" oraz "do lat 35", zmienna "Paracetamol" także jest silnie powiązana, ale ze zmienną "powyżej 55". Natomiast lek "Ibuprofen" wykazuje najsilniejszą korespondencję z grupą wiekową "od 36 do 55".

### Zad 3

Na podstawie danych zawartych w tablicy 1, obliczyć (odpowiednią) miarę współzmienności zmiennych Wynagrodzenie i Stopień zadowolenia z pracy (dane te są trochę inne niż te rozpatrywane na poprzedniej liście). Następnie, przeprowadzić analizę korespondencji, tzn. obliczyć wartości odpowiednich macierzy, współrzędnych punktów oraz utworzyć odpowiednie wykresy.

Wynagrodzenie	Stopień zadowolenia z pracy			
	b. niezadow.	niezadow.	zadow.	b. zadow.
do 6000	32	44	60	70
6000-15000	22	38	104	125
15000-25000	13	48	61	113
powyżej 25000	3	18	54	96

Tabela 9. Dane do listy 8 i 9, zadanie 3.

	$\tau$	V	T	$\varphi$	C	$\hat{\gamma}$
1	0.01671	0.13847	0.13847	0.23984	0.60416	0.21810


Tabela 10. Tablica wartości współczynników dla zadania 3.

Ze względu na to że badana tabela zawiera dwie zmienne katgoryczne i uporządkowane, możemy w tym przypadku posłużyć się dodatkowym współczynnikiem  $\hat{\gamma}$ .

	$\lambda$	inercja cz.
Zad 3	0.05752	0.98946

Tabela 11. Tablica wartości współczynników inercji macierzy dla zadania 3.

Inercja całkowita wynosi 0.05752, a częściowa aż 0.98946, co oznacza, że aż 98.95% zmienności jest objaśnione w dwóch wymiarach.



Rysunek 6. Analiza korespondencji dla Tabeli 3.

Wartość  $\hat{\gamma}$  wskazują, że między zmiennymi "Wynagrodzenie" oraz "Stopień zadowolenia z pracy" istnieje współzmiennność. Z powyższego wykresu korespondencji możemy wywnioskować, że najsłabiej rozróżnialnymi zmiennymi są kategorie "b.zadow" oraz "zadow" i "6000-15000", wskazują na to mała odległość od punktu  $(0,0)$  na wykresie. Najdalej, od wcześniej wspomnianego punktu, leży natomiast odpowiedź "b.niezadow", co wskazuje, że to ta kategoria jest najbardziej rozróżnialna. Silne powiązanie występuje między odpowiedziami "b.niezadow" i "do 6000".